고객을 세그먼테이션하자 [프로젝트] 김지수

11-2. 데이터 불러오기

데이터 살펴보기

- **테이블에 있는 10개의 행만 출력하기**

```
SELECT *
FROM `ivory-partition-473602-u6.modulabs_project.data_user`
LIMIT 10;
```

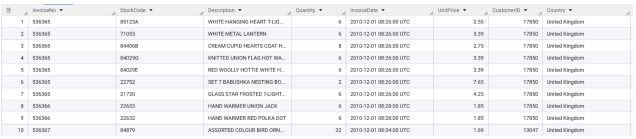

- **전체 데이터는 몇 행으로 구성되어 있는지 확인하기**

```
SELECT
 COUNT(*) AS total_rows
FROM `ivory-partition-473602-u6.modulabs_project.data_user`;
```

행	total_rows
1	541909

데이터 수 세기

- **COUNT 함수를 사용해서, 각 컬럼별 데이터 포인트의 수를 세어 보기**

```
SELECT
 COUNT(InvoiceNo) AS InvoiceNo_count,
 COUNT(StockCode) AS StockCode_count,
 COUNT(Description) AS Description_count,
 COUNT(Quantity) AS Quantity_count,
 COUNT(InvoiceDate) AS InvoiceDate_count,
 COUNT(UnitPrice) AS UnitPrice_count,
 COUNT(CustomerID) AS CustomerID_count,
 COUNT(Country) AS Country_count
FROM `ivory-partition-473602-u6.modulabs_project.data_user`;
```

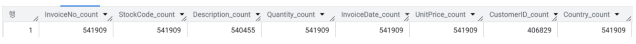

11-4. 데이터 전처리 방법(1): 결측치 제거

컬럼 별 누락된 값의 비율 계산

- **각 컬럼 별 누락된 값의 비율을 계산**
  - **각 컬럼에 대해서 누락 값을 계산한 후, 계산된 누락 값을 UNION ALL을 통해 합치기**

```
-- NULL 개수 확인
SELECT
```

```
  COUNT(*) - COUNT(InvoiceNo)   AS InvoiceNo_nulls,
  COUNT(*) - COUNT(StockCode)   AS StockCode_nulls,
  COUNT(*) - COUNT(Description) AS Description_nulls,
  COUNT(*) - COUNT(Quantity)    AS Quantity_nulls,
  COUNT(*) - COUNT(InvoiceDate) AS InvoiceDate_nulls,
  COUNT(*) - COUNT(UnitPrice)   AS UnitPrice_nulls,
  COUNT(*) - COUNT(CustomerID)  AS CustomerID_nulls,
  COUNT(*) - COUNT(Country)     AS Country_nulls
FROM `ivory-partition-473602-u6.modulabs_project.data_user`;

-- 컬럼별 결측치 비율
SELECT
   'InvoiceNo' AS column_name,
   ROUND(SUM(CASE WHEN InvoiceNo IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2) AS missing_percentage
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'StockCode', ROUND(SUM(CASE WHEN StockCode IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'Description', ROUND(SUM(CASE WHEN Description IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'Quantity', ROUND(SUM(CASE WHEN Quantity IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'InvoiceDate', ROUND(SUM(CASE WHEN InvoiceDate IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'UnitPrice', ROUND(SUM(CASE WHEN UnitPrice IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'CustomerID', ROUND(SUM(CASE WHEN CustomerID IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`

UNION ALL
SELECT 'Country', ROUND(SUM(CASE WHEN Country IS NULL THEN 1 ELSE 0 END) / COUNT(*) * 100, 2)
FROM `ivory-partition-473602-u6.modulabs_project.data_user`;
```

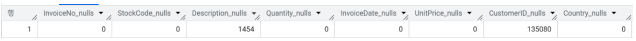

행	column_name	missing_percenta...
1	CustomerID	24.93
2	Quantity	0.0
3	Description	0.27
4	Country	0.0
5	InvoiceNo	0.0
6	InvoiceDate	0.0
7	UnitPrice	0.0
8	StockCode	0.0

결측치 처리 전략

- `StockCode = '85123A'` 의 `Description` 을 추출하는 쿼리문을 작성하기

```
SELECT DISTINCT Description
FROM project_name.modulabs_project.data
WHERE StockCode = '85123A';
```

행	Description
1	WHITE HANGING HEART T-LIG...
2	?
3	wrongly marked carton 22804
4	CREAM HANGING HEART T-LIG...

결측치 처리

- **DELETE 구문을 사용하며, WHERE 절을 통해 데이터를 제거할 조건을 제시**

```
DELETE FROM project_name.modulabs_project.data
WHERE CustomerID IS NULL
 OR Description IS NULL;
```

이 문으로 data_user의 행 135,080개가 삭제되었습니다.

11-5. 데이터 전처리(2): 중복값 처리

중복값 확인

- **중복된 행의 수를 세어보기**
  - **8개의 컬럼에 그룹 함수를 적용한 후, COUNT가 1보다 큰 데이터를 세어보기**

```
SELECT
 COUNT(*) AS duplicate_count
FROM (
   SELECT InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country,
   COUNT(*) AS cnt
   FROM project_name.modulabs_project.data
   GROUP BY InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country
   HAVING COUNT(*) > 1
);
```

행	duplicate_count
1	4837

중복값 처리

- **중복값을 제거하는 쿼리문 작성하기**
  - **CREATE OR REPLACE TABLE 구문을 활용하여 모든 컬럼(*)을 DISTINCT 한 데이터로 업데이트**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT DISTINCT *
```

```
FROM project_name.modulabs_project.data;
```

11-6. 데이터 전처리(3): 오류값 처리

InvoiceNo 살펴보기

- **고유(unique)한 InvoiceNo의 개수를 출력하기**

```
SELECT
 COUNT(DISTINCT InvoiceNo) AS unique_invoice_count
FROM `ivory-partition-473602-u6.modulabs_project.data_user`;
```

행	unique_invoice_c...
1	22190

- **고유한 InvoiceNo를 앞에서부터 100개를 출력하기**

```
SELECT
 DISTINCT InvoiceNo
FROM `ivory-partition-473602-u6.modulabs_project.data_user`
LIMIT 100;
```

행	InvoiceNo
1	541431
2	C541433
3	537626
4	542237
5	549222
6	556201
7	562032
8	573511
9	581180
10	539318
11	541998
12	548955

- **InvoiceNo가 'C'로 시작하는 행을 필터링 할 수 있는 쿼리문을 작성하기 (100행까지만 출력)**

```
SELECT *
FROM project_name.modulabs_project.data
WHERE InvoiceNo LIKE 'C%'
LIMIT 100;
```

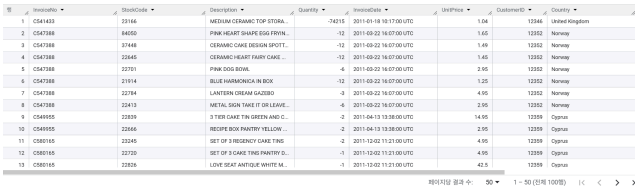

- **구매 건 상태가 `Canceled` 인 데이터의 비율(%) - 소수점 첫번째 자리까지**

```
SELECT ROUND(SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END)/ COUNT(*) * 100, 1)
FROM project_name.modulabs_project.data;
```

행	f0_
1	2.2

`StockCode` 살펴보기

- **고유한 `StockCode`의 개수를 출력하기**

```
SELECT
 COUNT(DISTINCT StockCode) AS unique_stockcodes
FROM `project_name.modulabs_project.data`;
```

행	unique_stockcodes
1	3684

- **어떤 제품이 가장 많이 판매되었는지 보기 위하여 `StockCode` 별 등장 빈도를 출력하기**
  - 상위 10개의 제품들을 출력하기

```
SELECT StockCode, COUNT(*) AS sell_cnt
FROM project_name.modulabs_project.data
GROUP BY StockCode
ORDER BY sell_cnt DESC
LIMIT 10;
```

행	StockCode	sell_cnt
1	85123A	2077
2	22423	1905
3	85099B	1662
4	84879	1418
5	47566	1416
6	20725	1359
7	22720	1232
8	POST	1196
9	20727	1126
10	22197	1118

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값**들에는 어떤 코드들이 들어가 있는지 출력하기

```
SELECT DISTINCT StockCode, number_count
FROM (
  SELECT StockCode,
    LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) AS number_count
  FROM project_name.modulabs_project.data
)
WHERE number_count BETWEEN 0 AND 1;
```

행	StockCode	number_count
1	POST	0
2	M	0
3	C2	1
4	D	0
5	BANK CHARGES	0
6	PADS	0
7	DOT	0
8	CRUK	0

- `StockCode` **의 컬럼에 있던 값 중에서 숫자를 제외한 문자만 남기고 문자가 몇 자리 수 인지 세고**
  - **숫자가 0~1개인 값들을 가지고 있는 데이터 수는 전체 데이터 수 대비 몇 퍼센트**인지 구하기 (소수점 두 번째 자리까지)

```
SELECT
  ROUND(100 * SUM(CASE WHEN LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) IN (0, 1)
                THEN 1 ELSE 0 END) / COUNT(*), 2) AS percentage
FROM project_name.modulabs_project.data;
```

행	percentage
1	0.48

- **제품과 관련되지 않은 거래 기록을 제거하기**

```
DELETE FROM project_name.modulabs_project.data
WHERE StockCode IN (
  SELECT DISTINCT StockCode
    FROM (
      SELECT StockCode
    FROM project_name.modulabs_project.data
    WHERE LENGTH(StockCode) - LENGTH(REGEXP_REPLACE(StockCode, r'[0-9]', '')) IN (0, 1)
  )
);
```

이 문으로 data_user의 행 1,915개가 삭제되었습니다.

Description 살펴보기

- **고유한 Description 별 출현 빈도를 계산하고 상위 30개를 출력하기**

```
SELECT Description, COUNT(*) AS description_cnt
FROM project_name.modulabs_project.data
GROUP BY Description
ORDER BY description_cnt DESC
LIMIT 30;
```

[결과 이미지를 넣어주세요]

- **서비스 관련 정보를 포함하는 행들을 제거하기**

```
DELETE
FROM project_name.modulabs_project.data
WHERE
# [[YOUR QUERY]]
```

행	Description	description_cnt
1	WHITE HANGING HEART T-LIG...	2058
2	REGENCY CAKESTAND 3 TIER	1894
3	JUMBO BAG RED RETROSPOT	1659
4	PARTY BUNTING	1409
5	ASSORTED COLOUR BIRD ORN...	1405
6	LUNCH BAG RED RETROSPOT	1345
7	SET OF 3 CAKE TINS PANTRY D...	1224
8	LUNCH BAG BLACK SKULL.	1099
9	PACK OF 72 RETROSPOT CAKE ...	1062
10	SPOTTY BUNTING	1026

페이지당 결과 수: 50 1 – 30 (전체 30행)

- **대소문자를 혼합하고 있는 데이터를 대문자로 표준화 하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT
  * EXCEPT (Description),
  UPPER(Description) AS Description
FROM project_name.modulabs_project.data;
```

이 문으로 이름이 data_user인 테이블이 교체되었습니다.

UnitPrice 살펴보기

- **UnitPrice의 최솟값, 최댓값, 평균을 구하기**

```
SELECT
 MIN(UnitPrice) AS min_price,
 MAX(UnitPrice) AS max_price,
 AVG(UnitPrice) AS avg_price
FROM project_name.modulabs_project.data;
```

행	min_price	max_price	avg_price
1	0.0	649.5	2.907457172952...

- **단가가 0원인 거래의 개수, 구매 수량(`Quantity`)의 최솟값, 최댓값, 평균 구하기**

```
SELECT
 COUNT(*) AS cnt_quantity,
  MIN(Quantity) AS min_quantity,
  MAX(Quantity) AS max_quantity,
  AVG(Quantity) AS avg_quantity
FROM project_name.modulabs_project.data
WHERE UnitPrice = 0;
```

행	cnt_quantity	min_quantity	max_quantity	avg_quantity
1	33	1	12540	420.5151515151...

- `UnitPrice = 0` **를 제거하고 일관된 데이터셋을 유지하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.data AS
SELECT *
FROM project_name.modulabs_project.data
WHERE UnitPrice <> 0;
```

이 문으로 이름이 data_user인 테이블이 교체되었습니다.

11-7. RFM 스코어

Recency

- `InvoiceDate` **컬럼을 연월일 자료형으로 변경하기**

```
SELECT DATE(InvoiceDate) AS InvoiceDay, *
FROM project_name.modulabs_project.data;
```

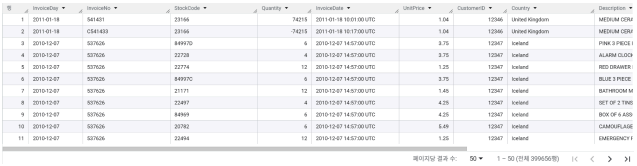

- **가장 최근 구매 일자를 MAX() 함수로 찾아보기**

```
SELECT
  (SELECT MAX(InvoiceDate) FROM project_name.modulabs_project.data) AS most_recent_date,
  DATE(InvoiceDate) AS InvoiceDay,
  *
FROM project_name.modulabs_project.data;
```

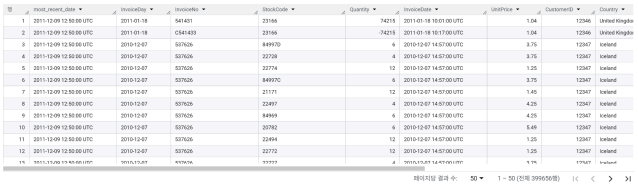

- **유저 별로 가장 큰 InvoiceDay를 찾아서 가장 최근 구매일로 저장하기**

```
SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
FROM project_name.modulabs_project.data
GROUP BY CustomerID;
```

행	CustomerID	InvoiceDay
1	12346	2011-01-18
2	12347	2011-12-07
3	12348	2011-09-25
4	12349	2011-11-21
5	12350	2011-02-02
6	12352	2011-11-03
7	12353	2011-05-19
8	12354	2011-04-21
9	12355	2011-05-09
10	12356	2011-11-17
11	12357	2011-11-06

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **가장 최근 일자(`most_recent_date`)와 유저별 마지막 구매일(`InvoiceDay`)간의 차이를 계산하기**

```
SELECT
  CustomerID,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM project_name.modulabs_project.data
  GROUP BY CustomerID
);
```

행	CustomerID	recency
1	12528	9
2	12685	28
3	12758	116
4	12863	52
5	12886	67
6	12995	77
7	13035	57
8	13141	84
9	13183	7
10	13328	316
11	13581	309

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **최종 데이터 셋에 필요한 데이터들을 각각 정제해서 이어붙이고 지금까지의 결과를 `user_r` 이라는 이름의 테이블로 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_r AS
SELECT
  CustomerID,
  InvoiceDay,
  MAX(InvoiceDay) OVER () AS most_recent_date,
  EXTRACT(DAY FROM MAX(InvoiceDay) OVER () - InvoiceDay) AS recency
FROM (
  SELECT
    CustomerID,
    MAX(DATE(InvoiceDate)) AS InvoiceDay
  FROM project_name.modulabs_project.data
  WHERE UnitPrice > 0
    AND CustomerID IS NOT NULL
  GROUP BY CustomerID
);
```

행	CustomerID	InvoiceDay	most_recent_date	recency
1	16446	2011-12-09	2011-12-09	0
2	17428	2011-12-09	2011-12-09	0
3	14446	2011-12-09	2011-12-09	0
4	12423	2011-12-09	2011-12-09	0
5	17581	2011-12-09	2011-12-09	0
6	15344	2011-12-09	2011-12-09	0
7	15910	2011-12-09	2011-12-09	0
8	16705	2011-12-09	2011-12-09	0
9	15804	2011-12-09	2011-12-09	0
10	12433	2011-12-09	2011-12-09	0

페이지당 결과 수: 50 1 – 50 (전체 4362행)

Frequency

- **고객마다 고유한 InvoiceNo의 수를 세어보기**

```
SELECT
  CustomerID,
  COUNT(DISTINCT InvoiceNo) AS purchase_cnt
FROM project_name.modulabs_project.data
WHERE UnitPrice > 0
  AND CustomerID IS NOT NULL
GROUP BY CustomerID;
```

행	CustomerID	purchase_cnt
1	12346	2
2	12347	7
3	12348	4
4	12349	1
5	12350	1
6	12352	8
7	12353	1
8	12354	1
9	12355	1
10	12356	3
11	12357	1

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **각 고객 별로 구매한 아이템의 총 수량 더하기**

```
SELECT
  CustomerID,
  SUM(Quantity) AS item_cnt
FROM project_name.modulabs_project.data
WHERE UnitPrice > 0
  AND CustomerID IS NOT NULL
GROUP BY CustomerID;
```

행	CustomerID	item_cnt
1	12346	0
2	12347	2458
3	12348	2332
4	12349	630
5	12350	196
6	12352	463
7	12353	20
8	12354	530
9	12355	240
10	12356	1573
11	12357	2708

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **전체 거래 건수 계산와 구매한 아이템의 총 수량 계산의 결과를 합쳐서 `user_rf` 라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_rf AS

-- (1) 전체 거래 건수 계산
WITH purchase_cnt AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT InvoiceNo) AS purchase_cnt
  FROM project_name.modulabs_project.data
  WHERE UnitPrice > 0
    AND CustomerID IS NOT NULL
  GROUP BY CustomerID
),

-- (2) 구매한 아이템 총 수량 계산
item_cnt AS (
  SELECT
    CustomerID,
    SUM(Quantity) AS item_cnt
  FROM project_name.modulabs_project.data
  WHERE UnitPrice > 0
    AND CustomerID IS NOT NULL
  GROUP BY CustomerID
)

-- 기존의 user_r에 (1)과 (2)를 통합
SELECT
  pc.CustomerID,
  pc.purchase_cnt,
  ic.item_cnt,
  ur.recency
FROM purchase_cnt AS pc
JOIN item_cnt AS ic
  ON pc.CustomerID = ic.CustomerID
```

```
JOIN project_name.modulabs_project.user_r AS ur
  ON pc.CustomerID = ur.CustomerID;
```

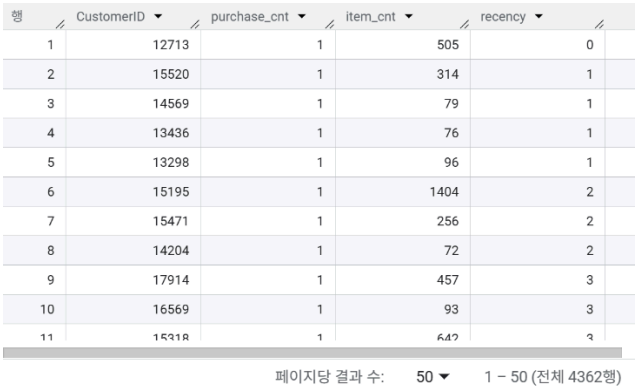

행	CustomerID	purchase_cnt	item_cnt	recency
1	12713	1	505	0
2	15520	1	314	1
3	14569	1	79	1
4	13436	1	76	1
5	13298	1	96	1
6	15195	1	1404	2
7	15471	1	256	2
8	14204	1	72	2
9	17914	1	457	3
10	16569	1	93	3
11	15318	1	642	3

페이지당 결과 수: 50 1 – 50 (전체 4362행)

Monetary

- **고객별 총 지출액 계산 (소수점 첫째 자리에서 반올림)**

```
SELECT
  CustomerID,
  ROUND(SUM(Quantity * UnitPrice), 1) AS user_total
FROM project_name.modulabs_project.data
WHERE UnitPrice > 0
  AND CustomerID IS NOT NULL
GROUP BY CustomerID;
```

행	CustomerID	user_total
1	12346	0.0
2	12347	4310.0
3	12348	1437.2
4	12349	1457.5
5	12350	294.4
6	12352	1265.4
7	12353	89.0
8	12354	1079.4
9	12355	459.4
10	12356	2487.4
11	12357	6207.7

페이지당 결과 수: 50 1 – 50 (전체 4362행)

- **고객별 평균 거래 금액 계산**
  - **고객별 평균 거래 금액을 구하기 위해 1)** `data` **테이블을** `user_rf` **테이블과 조인(LEFT JOIN) 한 후, 2)** `purchase_cnt` **로 나누어서 3)** `user_rfm` **테이블로 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_rfm AS
SELECT
  rf.CustomerID AS CustomerID,
  rf.purchase_cnt,
  rf.item_cnt,
  rf.recency,
  ut.user_total,
  ROUND(ut.user_total / rf.purchase_cnt, 1) AS user_average
```

```
FROM project_name.modulabs_project.user_rf rf
LEFT JOIN (
  -- 고객 별 총 지출액
  SELECT
    CustomerID,
    ROUND(SUM(Quantity * UnitPrice), 1) AS user_total
  FROM project_name.modulabs_project.data
  WHERE UnitPrice > 0
    AND CustomerID IS NOT NULL
  GROUP BY CustomerID
) ut
ON rf.CustomerID = ut.CustomerID;
```

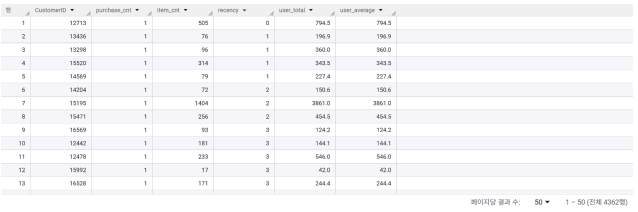

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	794.5	794.5
2	13436	1	76	1	196.9	196.9
3	13298	1	96	1	360.0	360.0
4	15520	1	314	1	343.5	343.5
5	14569	1	79	1	227.4	227.4
6	14204	1	72	2	150.6	150.6
7	15195	1	1404	2	3861.0	3861.0
8	15471	1	256	2	454.5	454.5
9	16569	1	93	3	124.2	124.2
10	12442	1	181	3	144.1	144.1
11	12478	1	233	3	546.0	546.0
12	15992	1	17	3	42.0	42.0
13	16528	1	171	3	244.4	244.4

페이지당 결과 수: 50 1 – 50 (전체 4362행)

RFM 통합 테이블 출력하기

- **최종 user_rfm 테이블을 출력하기**

```
SELECT *
FROM project_name.modulabs_project.user_rfm;
```

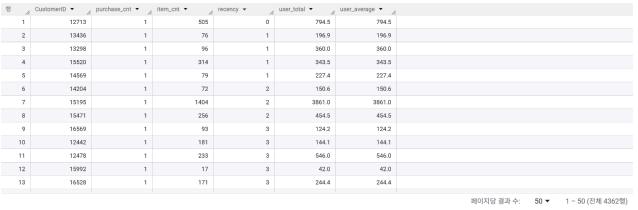

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average
1	12713	1	505	0	794.5	794.5
2	13436	1	76	1	196.9	196.9
3	13298	1	96	1	360.0	360.0
4	15520	1	314	1	343.5	343.5
5	14569	1	79	1	227.4	227.4
6	14204	1	72	2	150.6	150.6
7	15195	1	1404	2	3861.0	3861.0
8	15471	1	256	2	454.5	454.5
9	16569	1	93	3	124.2	124.2
10	12442	1	181	3	144.1	144.1
11	12478	1	233	3	546.0	546.0
12	15992	1	17	3	42.0	42.0
13	16528	1	171	3	244.4	244.4

페이지당 결과 수: 50 1 – 50 (전체 4362행)

11-8. 추가 Feature 추출

1. 구매하는 제품의 다양성

- **1) 고객 별로 구매한 상품들의 고유한 수를 계산하기**
  2) `user_rfm` **테이블과 결과를 합치기**
  3) `user_data` **라는 이름의 테이블에 저장하기**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS
WITH unique_products AS (
  SELECT
    CustomerID,
    COUNT(DISTINCT StockCode) AS unique_products
  FROM project_name.modulabs_project.data
  GROUP BY CustomerID
)
SELECT ur.*, up.* EXCEPT (CustomerID)
FROM project_name.modulabs_project.user_rfm AS ur
```

```
JOIN unique_products AS up
ON ur.CustomerID = up.CustomerID;
```

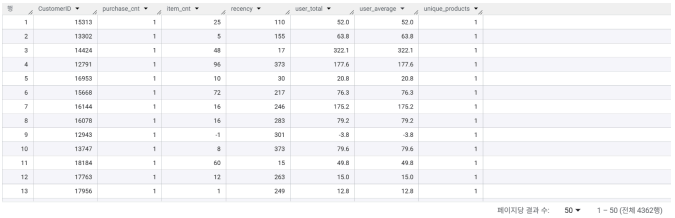

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products
1	15313	1	25	110	52.0	52.0	1
2	13902	1	5	155	63.8	63.8	1
3	14424	1	48	17	322.1	322.1	1
4	12791	1	96	373	177.6	177.6	1
5	16953	1	10	30	20.8	20.8	1
6	15668	1	72	217	76.3	76.3	1
7	16144	1	16	246	175.2	175.2	1
8	16078	1	16	283	79.2	79.2	1
9	12943	1	-1	301	-3.8	-3.8	1
10	13747	1	8	373	79.6	79.6	1
11	18184	1	60	15	49.8	49.8	1
12	17763	1	12	263	15.0	15.0	1
13	17956	1	1	249	12.8	12.8	1

페이지당 결과 수: 50 1 – 50 (전체 4362행)

2. 평균 구매 주기

- **고객들의 쇼핑 패턴을 이해하는 것을 목표 (고객 별 재방문 주기 살펴보기)**
  - **균 구매 소요 일수를 계산하고, 그 결과를 `user_data` 에 통합**

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS
WITH purchase_intervals AS (
  -- (2) 고객 별 구매와 구매 사이의 평균 소요 일수
  SELECT
    CustomerID,
    CASE WHEN ROUND(AVG(interval_), 2) IS NULL THEN 0 ELSE ROUND(AVG(interval_), 2) END AS average_interval
  FROM (
    -- (1) 구매와 구매 사이에 소요된 일수
    SELECT
      CustomerID,
      DATE_DIFF(InvoiceDate, LAG(InvoiceDate) OVER (PARTITION BY CustomerID ORDER BY InvoiceDate), DAY) AS interval_
    FROM
      project_name.modulabs_project.data
    WHERE CustomerID IS NOT NULL
  )
  GROUP BY CustomerID
)

SELECT u.*, pi.* EXCEPT (CustomerID)
FROM project_name.modulabs_project.user_data AS u
LEFT JOIN purchase_intervals AS pi
ON u.CustomerID = pi.CustomerID;
```

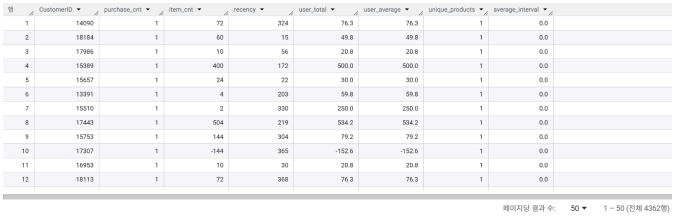

행	CustomerID	purchase_cnt	item_cnt	recency	user_total	user_average	unique_products	average_interval
1	14090	1	72	324	76.3	76.3	1	0.0
2	18184	1	60	15	49.8	49.8	1	0.0
3	17986	1	10	56	20.8	20.8	1	0.0
4	15389	1	400	172	500.0	500.0	1	0.0
5	15657	1	24	22	30.0	30.0	1	0.0
6	13391	1	4	203	59.8	59.8	1	0.0
7	15510	1	2	330	250.0	250.0	1	0.0
8	17443	1	504	219	534.2	534.2	1	0.0
9	15753	1	144	304	79.2	79.2	1	0.0
10	17307	1	-144	365	-152.6	-152.6	1	0.0
11	16953	1	10	30	20.8	20.8	1	0.0
12	18113	1	72	368	76.3	76.3	1	0.0

페이지당 결과 수: 50 1 – 50 (전체 4362행)

3. 구매 취소 경향성

- **고객의 취소 패턴 파악하기**
  1) 취소 빈도(cancel_frequency) : 고객 별로 취소한 거래의 총 횟수
  2) 취소 비율(cancel_rate) : 각 고객이 한 모든 거래 중에서 취소를 한 거래의 비율
  - **취소 빈도와 취소 비율을 계산하고 그 결과를 `user_data` 에 통합하기**
    (취소 비율은 소수점 두번째 자리)

```
CREATE OR REPLACE TABLE project_name.modulabs_project.user_data AS

WITH TransactionInfo AS (
  SELECT
    CustomerID,
     COUNT(*) AS total_transactions,
     SUM(CASE WHEN InvoiceNo LIKE 'C%' THEN 1 ELSE 0 END) AS cancel_frequency
  FROM project_name.modulabs_project.data
  WHERE CustomerID IS NOT NULL
  GROUP BY CustomerID
)

SELECT
  u.*,
  t.* EXCEPT(CustomerID),
  ROUND(t.cancel_frequency / t.total_transactions, 2) AS cancel_rate
FROM `project_name.modulabs_project.user_data` AS u
LEFT JOIN TransactionInfo AS t
ON u.CustomerID = t.CustomerID;
```

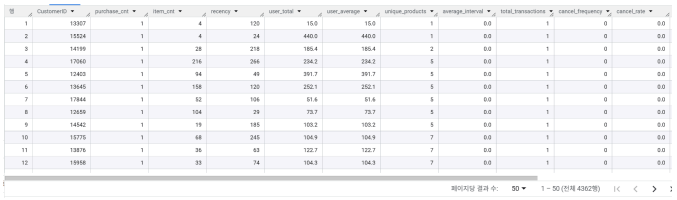

- **다양한 컬럼들을 활용하여 고객의 구매 패턴과 선호도를 보다 심층적으로 이해할 수 있도록 최종적으로 `user_data` 를 출력하기**

```
SELECT *
FROM project_name.modulabs_project.user_data
ORDER BY recency ASC
LIMIT 100;
```

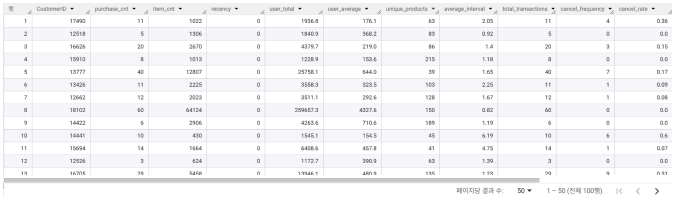

회고

[회고 내용을 작성해주세요]

Keep :

- 단계별로 데이터를 정제하고, 불필요한 값을 제거한 과정
- Recency, Frequency, Monrtary를 포함한 고객별 핵심 Feature를 체계적으로 계산하고 통합한 점
- 추가 Feature를 통해 고객 구매 패턴과 선호도를 심층적으로 이해할 수 있도록 확장한 점
- 서브쿼리, 윈도우 함수, 집계 함수 등 SQL기능을 적절히 활용하여 복잡한 계산을 효율적으로 처리한 점

Problem :

- 일부 쿼리에서 집계 함수와 일발 컬럼 혼합으로 오류가 발생(max() + * 문제)
- 날짜 차이를 계산할 때 DATE_DIFF와 EXTRACT 사용 방식이 혼동되어 잠시 시행착오 발생
- 여러 Feature를 통합할 때 컬럼 이름 중복 문제 발생

Try :

- 집계 함수와 일반 컬럼을 사용할 때는 윈도우 함수 또는 서브쿼리를 적극 활용하여 오류 방지
- 추가 Feature를 설계할 때는 단계별로 CTE를 활용하여 가독성과 재사용성을 높이기
- 추후 분석에서는 고객 세그먼트별 통계 요약이나 시각화까지 연결하여 분석 결과를 직관적으로 확인